PRODUCT REQUIREMENTS DOCUMENT

AI De_Para Categorizer

Versão 1.0 | Fevereiro 2026
Classificação: Interno | Status: Draft para desenvolvimento

1. Overview do Produto

O AI De_Para Categorizer é uma aplicação web local (Flask + HTML/CSS/JS) que utiliza a API da OpenAI para automatizar o processo de categorização semântica em massa — o chamado "De_Para" — de itens descritos em linguagem natural (ex: nomes de SKU, centros de custo, descrições de contratos) para categorias pré-definidas pelo analista.

Problema resolvido

Bases com +10.000 linhas tornam inviável a categorização manual item a item. A aplicação elimina esse gargalo ao enviar os dados em batches para um LLM que interpreta semanticamente cada descrição e retorna a categoria com maior aderência — sem exigir correspondência exata de strings.

Resultado esperado

O analista faz upload da base, define as categorias com suas descrições, executa o processamento e baixa o arquivo original acrescido de uma coluna "Categoria_IA" — pronto para uso em análises e apresentações.

2. Objetivos e Métricas de Sucesso

2.1 Objetivos

- Automatizar categorização semântica de grandes volumes de dados sem código adicional pelo usuário
- Eliminar risco de ultrapassar o context window via chunking automático e transparente
- Garantir output diretamente utilizável (.xlsx ou .csv) sem pós-processamento manual
- Ser operável por qualquer analista com Python instalado — sem conhecimento técnico adicional

2.2 Métricas de Sucesso (v1.0)

Métrica	Target	Observação

Precisão de categorização	>85% de acerto	Validação humana em amostra
Tempo de processamento (1k linhas)	<3 minutos	GPT-4o mini, batch 50
Taxa de erro de API	<2%	Com retry automático
Setup time para novo usuário	<10 minutos	Inclui instalação deps

3. Usuários-Alvo

Analistas e consultores estratégicos que trabalham com grandes bases de dados estruturadas no contexto de projetos de due diligence, benchmarking, reestruturação organizacional ou eficiência operacional — onde o agrupamento semântico de itens heterogêneos é etapa recorrente do workflow analítico.

Nível técnico esperado:

- Sabe instalar Python e rodar comandos básicos no terminal
- Não necessariamente sabe programar ou configurar ambientes de desenvolvimento
- Trabalha com Excel/CSV diariamente

4. Funcionalidades — Escopo v1.0

4.1 Configuração de API

- Campo para inserir chave de API OpenAI diretamente na interface
- Opção de salvar a chave localmente em arquivo .env para não precisar reinserir
- Seleção do modelo a ser usado (default: gpt-4o-mini; opção para gpt-4o)

4.2 Upload da Base de Dados

- Upload de arquivos .xlsx e .csv
- Preview das primeiras 10 linhas após o upload
- Seleção da coluna que contém a descrição a ser categorizada (dropdown com os nomes das colunas)

4.3 Definição de Categorias

- Interface para adicionar categorias dinamicamente (botão "+ Adicionar Categoria")
- Cada categoria tem dois campos: Nome (obrigatório) e Descrição (opcional, para orientar o modelo)
- Opção de remover categorias individualmente
- Mínimo de 2 categorias para habilitar o processamento

4.4 Processamento com IA

- Chunking automático da base em lotes de 50 linhas (configurável via settings)

- Barra de progresso em tempo real indicando lotes processados vs. total
- Retry automático (até 3 tentativas) em caso de erro de API por lote
- Log de erros visível ao usuário — lotes com falha são identificados e o usuário pode reprocessar somente eles
- O modelo recebe: lista de categorias com descrições + bloco de descrições do lote; retorna somente o nome exato da categoria para cada item

4.5 Output

- Download do arquivo original com nova coluna "Categoria_IA" adicionada ao final
- Formato de saída igual ao de entrada (.xlsx ou .csv)
- Coluna de confiança opcional: o modelo pode retornar junto um score de confiança (Alta / Média / Baixa)
- Preview do resultado (primeiras 20 linhas) antes do download

5. Arquitetura Técnica

5.1 Stack

Camada	Tecnologia	Justificativa
Backend	Python + Flask	Leve, simples, sem overhead
Frontend	HTML + CSS + JS puro	Design 100% customizável, sem lock-in de framework
Processamento de dados	pandas	Padrão para manipulação de .xlsx/.csv em Python
API LLM	OpenAI Python SDK	Provedor inicial; arquitetura permite troca
Comunicação frontend-backend	Fetch API (REST)	SSE para streaming do progresso

5.2 Estrutura de Arquivos

Arquivo / Pasta	Responsabilidade
app.py	Servidor Flask: rotas, orquestração do processamento
categorizer.py	Lógica de chunking, chamada à API OpenAI, retry
templates/index.html	Interface principal do app
static/style.css	Design e layout — livre para customização
static/script.js	Interatividade do frontend, upload, progresso, download
.env	Chave de API (não versionado no git)
requirements.txt	Dependências Python do projeto

5.3 Fluxo de Processamento

- Usuário faz upload do arquivo → Flask salva em diretório temporário → pandas lê e extrai colunas disponíveis
- Usuário define categorias e seleciona coluna → clica em "Processar"
- Backend divide a coluna em chunks de N itens → para cada chunk, monta prompt estruturado com categorias e descrições
- Chamada à OpenAI API com temperature=0 para máxima consistência → parse do output linha a linha
- Resultado consolidado é adicionado como nova coluna → arquivo exportado para download

6. Design do Prompt

O prompt enviado à API para cada batch segue a estrutura abaixo. A qualidade do prompt é o principal driver de precisão da categorização.

```
SYSTEM:
You are a data categorization expert. Your task is to assign each item to exactly
one category from the provided list. Respond ONLY with the exact category name for
each item, one per line, in the same order as the input. No explanations, no
punctuation, no numbering.

USER:
Categories:
- {category_name}: {category_description}

Items to categorize:
1. {item_description}
2. {item_description}
...
```

7. Fora do Escopo — v1.0

- Autenticação de usuários ou multiusuário
- Histórico de sessões ou persistência de dados entre usos
- Suporte a outros provedores de LLM na interface (Claude, Gemini) — arquitetura permite mas não será exposto na v1.0
- Treinamento fine-tuning ou uso de embeddings — categorização puramente por prompt
- Deploy em nuvem ou acesso remoto
- Integração direta com Google Sheets ou outros sistemas externos

8. Roadmap — Versões Futuras

Versão	Tema	Funcionalidades
v1.1	Multi-provedor	Suporte a Claude (Anthropic) e Gemini além da OpenAI
v1.2	Validação assistida	Revisão inline de categorias com baixa confiança; exportação de amostra para validação humana

v1.3	Categorização hierárquica	Suporte a estruturas categoria > subcategoria
v2.0	Persistência de projetos	Salvar e reutilizar configurações de categorias entre sessões; histórico de execuções

9. Critérios de Aceitação — v1.0

A versão 1.0 está pronta para uso quando todos os critérios abaixo são atendidos:

- Upload de .xlsx e .csv funciona sem erros para arquivos de até 50MB
- Seleção de coluna popula corretamente com os nomes das colunas do arquivo
- Interface de categorias permite adicionar, descrever e remover categorias sem limitação de quantidade
- Processamento de base com 1.000 linhas completa em menos de 3 minutos usando gpt-4o-mini
- Coluna "Categoria_IA" no output contém apenas nomes exatos das categorias definidas (sem texto livre ou categorias inventadas)
- Falha em um batch não interrompe o processamento dos demais — itens com erro são sinalizados
- Download gera arquivo no mesmo formato do upload com a coluna adicional corretamente posicionada
- App roda com python app.py + acesso via localhost:5000 sem configuração adicional além do requirements.txt

10. Dependências e Pré-requisitos

10.1 Ambiente

- Python 3.9 ou superior
- pip para instalação das dependências
- Chave de API da OpenAI com créditos disponíveis

10.2 requirements.txt

```
flask>=3.0.0 pandas>=2.0.0 openpyxl>=3.1.0 openai>=1.0.0 python-dotenv>=1.0.0
```

11. Riscos e Mitigações

Risco	Probabilidade	Mitigação
Modelo retorna categoria não listada	Baixa	Prompt com instrução explícita; validação pós-processamento com fallback para "Não categorizado"

Rate limit da API OpenAI	Média	Delay configurável entre batches; retry com backoff exponencial
Custo elevado em bases muito grandes	Baixa	Estimativa de custo exibida antes de processar (tokens estimados × preço do modelo)
Precisão insatisfatória em categorias ambíguas	Média	Descrições detalhadas das categorias melhoram significativamente o resultado; instrução ao usuário